

1. 모델링 목표 정의

본 프로젝트의 목표는 YelpZip 리뷰 데이터를 활용하여 조직적 어뷰징 리뷰 네트워크를 탐지하는 것이다. 여기서 탐지하려는 대상은 단순히 문장이 짧거나 평점이 극단적인 리뷰가 아니다. 정상 사용자도 매우 만족하면 5 점을 줄 수 있고, 실제 불만이 강하면 1 점을 줄 수 있으며, 간단한 한두 문장으로 경험을 표현할 수도 있다. 따라서 본 프로젝트는 개별 리뷰 하나가 겉으로 얼마나 수상해 보이는지를 판단하기보다, 특정 상품과 특정 기간 안에서 리뷰가 어떤 사용자 이력, 상품 평판, 평점 이동, 텍스트 표현, 리뷰 간 관계와 함께 나타나는지를 중심으로 문제를 정의하였다.

리뷰 작성은 사용자가 의도와 동기를 가지고 수행하는 행동이다. 정상 리뷰는 실제 경험을 바탕으로 상품이나 서비스에 대한 평가를 남기는 행동이고, 어뷰징 리뷰는 특정 상품의 평판을 인위적으로 높이거나 낮추려는 행동일 가능성이 높다. 그러나 이러한 의도는 데이터에서 직접 관측되지 않는다. 우리가 볼 수 있는 것은 리뷰 본문, 평점, 작성 시점, 작성자 이력, 상품의 기존 평판, 그리고 다른 리뷰와의 관계뿐이다. 그러므로 모델링의 핵심은 관측 가능한 흔적을 이용하여 어뷰징 가능성이 높은 상황을 찾는 것이다.

이 관점에서 본 프로젝트의 모델링 목표는 “가짜처럼 보이는 리뷰를 찾는 것”에서 한 단계 더 나아가, “평판 조작이 발생하기 쉬운 상황과 그 상황에서 나타나는 행동 패턴을 그래프 구조로 표현하는 것”이다. 예를 들어 같은 상품의 특정 주간에 리뷰가 갑자기 늘어나고, 그 안에서 신규 사용자 비율이 높아지며, 평점이 상품의 과거 평균에서 크게 벗어난다면 이는 단일 리뷰보다 더 강한 맥락적 신호가 된다. 반대로 같은 사용자가 여러 리뷰를 작성했다는 사실만으로는 위험하다고 볼 수 없다. 활동적인 정상 사용자도 여러 리뷰를 남기기 때문이다.

따라서 최종 모델은 리뷰를 노드로 두고, 리뷰 자체의 피처와 리뷰 사이의 관계를 함께 학습하는 GNN 방식으로 설계하였다. 가이드라인에서 요구하는 것처럼 노드는 리뷰 단위로 고정하고, 기본 relation 으로 동일 사용자 기반 R-U-R 을 사용하며, 커스텀 relation 으로 상품 평점 shock relation 을 추가하였다. 최종 실행 기준 모델은 topk15 window60 SAGE 이며, 이 모델은 R-U-R 과 weak product shock 엣지가 포함된 graph_rur_custom2.pt 를 입력으로 사용한다. 다만 plain SAGE 이므로 edge_type 별로 서로 다른 가중치를 두지는 않고, 두 relation 을 하나의 이웃 그래프로 모아 메시지 전달에 활용한다.

이 설계의 의도는 모델을 지나치게 복잡하게 만드는 것이 아니라, EDA 에서 확인한 주요 단서를 비용 대비 효율적이고 해석 가능한 형태로 반영하는 것이다. 텍스트만 보는 모델은 조직적 행동의 맥락을 놓칠 수 있고, 단순한 상품-기간 버스트만 보는 모델은 정상적인 인기 상승이나 실제 사건에 따른 리뷰 증가를 어뷰징으로 오탐할 수 있다. 본 프로젝트는 이러한 두 한계를 피하기 위해 리뷰 자체 피처, 사용자 과거 맥락, 상품 과거 맥락, 상품-주 단위 샘플링, R-U-R relation, weak product shock relation 을 결합하였다.

2. 데이터 구성 및 전처리 과정

2-1. 사용 데이터

본 프로젝트는 Kaggle 의 YelpZip 원본 리뷰 데이터를 사용하였다. 이 데이터는 Yelp 플랫폼의 식당 및 비즈니스 리뷰로 구성되어 있으며, 각 행은 하나의 리뷰를 의미한다. 주요 컬럼은 리뷰 본문인 text, 작성자 식별자인 user_id, 리뷰 대상 상품 또는 식당을 나타내는 prod_id, 평점인 rating, 작성일인 date, 정답 라벨인 label, 추가 태그인 tag 이다. 모델의 노드는 이 원본 행 하나하나에 대응되는 리뷰 단위로 구성하였다.

전체 데이터는 608,458 건의 리뷰, 260,239 명의 사용자, 5,044 개의 상품 또는 식당으로 구성되어 있다. 날짜 범위는 전처리 산출물 기준 2004 년 10 월 20 일부터 2015 년 1 월 10 일까지이다. 원본 label 은 fake 리뷰가 -1, 정상 리뷰가 1 로 기록되어 있으므로, 모델 학습 전 fake 를 1, normal 을 0 으로 변환하였다. 이 변환은 가이드라인의 필수 전처리 조건이며, 이후 모든 모델과 평가에서 is_fake=1 이 탐지 대상 클래스를 의미한다.

전체 fake 리뷰는 80,439 건으로 전체의 약 13.22%이다. 정상 리뷰가 훨씬 많기 때문에 이 데이터는 클래스 불균형이 뚜렷하다. 이런 상황에서 단순 정확도만 높이는 모델은 실제 탐지 모델로 적절하지 않다. 예를 들어 모든 리뷰를 정상으로 예측하면 정확도는 높아 보일 수 있지만 fake 리뷰를 거의 찾지 못한다. 따라서 전처리와 샘플링 단계에서는 fake 리뷰만 과도하게 모으는 방식이 아니라, 정상 리뷰 분포를 유지하면서도 어뷰징 가능성이 있는 맥락을 충분히 포함하는 방향을 선택하였다.

또한 user_id 와 prod_id 는 그대로 모델 입력 피쳐로 넣지 않았다. ID 원값을 직접 넣으면 모델이 사용자나 상품 자체를 외우는 방식으로 학습할 가능성이 커진다. 본 프로젝트의 목적은 특정 ID 를 암기하는 것이 아니라, 리뷰 작성 시점에 관측 가능한 행동 맥락을 학습하는 것이다. 따라서 user_id 와 prod_id 는 과거 이력 계산과 옛지 생성에는 사용하되, 최종 노드 피쳐에는 사용자 과거 리뷰 수, 상품 과거 평균 평점, 상품 과거 평점 표준편차처럼 해석 가능한 요약값으로 변환하여 반영하였다.

2-1-1. EDA 를 통한 모델링 방향 도출

전처리와 그래프 설계를 바로 진행하기 전에, 먼저 탐색적 데이터 분석을 통해 어뷰징 리뷰가 어떤 상황에서 더 자주 나타나는지 확인하였다. 이 단계의 목적은 단순히 통계량을 나열하는 것이 아니라, 이후 샘플링 기준, 파생 변수, 그래프 옛지 설계가 왜 필요한지에 대한 논리적 근거를 마련하는 것이다. 리뷰 어뷰징은 작성자의 실제 의도와 관련된 문제이지만, 의도 자체는 데이터에서 관측되지 않는다. 따라서 평점, 텍스트 길이, 사용자 이력, 상품 이력, 시간적 집중 패턴을 통해 어뷰징 가능성이 높아지는 상황을 추론하였다.

첫째, 라벨 분포를 확인한 결과 전체 리뷰 중 fake 비율은 약 13.22%였다. 이는 정상 리뷰가 압도적으로 많은 불균형 데이터임을 의미한다. 따라서 모델은 정상 리뷰를 대량으로 오탐하지 않으면서도 fake 리뷰를 검토 대상으로 끌어올릴 수 있어야 한다. 이 때문에 모델 설계에서는 정상 사용자 맥락을 제거하지 않았고, 샘플링에서도 fake rate 를 직접 기준으로 사용하지 않았다. 라벨은 학습과 평가에만 사용하고, 샘플링 flag 와 옛지 생성 기준에는 사용하지 않는 방식으로 정보 누수와 라벨 의존을 줄였다.

둘째, 평점 분포를 보면 Yelp 리뷰는 전반적으로 4 점과 5 점에 많이 몰려 있다. 따라서 높은 평점 자체를 어뷰징 신호로 보는 것은 부적절하다. 그러나 평점별 fake rate 를 나누어 보면 1 점과 5 점처럼 극단적인 평점에서 fake 비율이 상대적으로 높게 나타난다. 이는 긍정 조작과 부정 공격 모두가 극단적인 평점 선택을 통해 상품 평판을 움직이려 할 수 있음을 시사한다. 그래서 최종 피쳐에는 rating 원값뿐 아니라 rating_direction, extreme_rating, 상품 과거 평균 대비 평점 이탈을 함께 포함하였다.

셋째, 텍스트 길이 분석에서는 fake 리뷰가 정상 리뷰보다 평균적으로 짧은 경향이 확인되었다. 그러나 “짧은 리뷰는 가짜”라는 규칙은 위험하다. 실제 사용자는 매우 만족하거나 실망했을 때 짧고 강한 표현만 남길 수 있다. 따라서 최종 모델은 단순 단어 수만 사용하는 것이 아니라, 같은 평점대와 상품 이력 구간 안에서 상대적으로 설명이 부족한지를 보는 피쳐를 추가하였다. 예를 들어 5 점 리뷰가 전체적으로 길게 작성되는 상품 이력 구간에서 유독 짧은 5 점 리뷰가 나타난다면, 단순히 짧다는 사실보다 맥락 대비 설명이 부족하다는 사실이 더 의미 있는 단서가 된다.


넷째, 사용자 관점에서는 신규 사용자 또는 리뷰 이력이 적은 사용자의 리뷰에서 fake 비율이 높아지는 경향이 확인되었다. 이는 어뷰징 행동이 일회성 계정이나 활동 이력이 적은 계정을 통해 나타날 가능성과 연결된다. 하지만 신규 사용자라고 해서 무조건 fake 라고 볼 수는 없으며, 활동량이 많은 사용자라고 해서 항상 정상이라고 볼 수도 없다. 따라서 사용자 피쳐는 ID 자체를 쓰는 방식이 아니라, 리뷰 작성 시점 이전에 관측 가능한 과거 리뷰 수, 과거 평균 평점, 과거 극단 평점 비율, 마지막 리뷰 이후 경과일 등으로 요약하였다.

다섯째, 상품 맥락에서는 리뷰 이력이 적은 상품일수록 개별 리뷰가 평판에 미치는 영향이 커질 수 있다는 점이 중요하다. 리뷰가 적은 상품은 하나의 5 점 또는 1 점 리뷰만으로도 평균 평점이 크게 움직일 수 있다. 반대로 이력이 많은 상품에서도 평점이 안정적으로 유지되던 상황에서 갑작스러운 극단 평점이 나타나면 평판 흐름의 변화를 의미할 수 있다. 따라서 상품 과거 리뷰 수, 상품 과거 평균 평점, 상품 과거 평점 표준편차, 현재 평점의 과거 평균 대비 이탈을 계산하였다.

여섯째, 시간적 집중은 GNN 샘플링과 옛지 설계의 핵심 단서가 되었다. 전체 월별 리뷰 수나 전체 요일별 fake rate 보다 중요한 것은 특정 상품의 특정 기간에 리뷰가 몰리는 현상이다. 다만 리뷰가 몰린다는 사실만으로도 어뷰징이라고 판단하면 정상적인 인기 상승이나 실제 사건에 따른 리뷰 증가를 잘못 탐지할 수 있다. 따라서 최종 샘플링은 개별 리뷰를 무작위로 뽑지 않고 상품 × 주 단위로 기본 gate 를 둔 뒤, 여러 행동 변화 flag 가 동시에 나타나는 구간을 선택하였다.

같은 상품, 같은 기간에 대한 리뷰 수별 Fake Rate 변화

상품 × 주 단위 그룹을 만들고, 그룹 내 리뷰 수 구간별로 fake 리뷰 비율을 계산



기간은 W-SUN 기준 주 단위로 묶었으며, 라벨은 원본 label=-1을 fake=1로 변환해 계산했다.

[같은 상품, 같은 기간에 대하여 리뷰수 별 Fake Rate 변화 그래프]

위 그래프는 같은 상품과 같은 주에 작성된 리뷰들을 하나의 그룹으로 묶고, 그룹 내 리뷰 수 구간별로 fake rate 를 계산한 결과이다. 리뷰가 1 개뿐인 그룹의 fake rate 도 높게 나타나지만, 이는 단발성 리뷰와 신규 사용자 효과가 섞여 있을 가능성이 크므로 곧바로 조직적 어뷰징으로 해석하기 어렵다. 반면 리뷰 수가 16 개 이상, 특히 21 개 이상으로 커지는 상품-주 그룹에서는 fake rate 가 전체 평균보다 다시 뚜렷하게 상승한다. 이 결과는 단순 무작위 샘플링보다 상품-주 단위의 밀도 중심 샘플링이 적합하다는 근거가 된다.

다만 이 그래프만으로 “리뷰가 많은 상품-주는 모두 위험하다”고 결론 내리지는 않았다. 리뷰 수가 5~10 개 정도인 구간에서는 fake rate 가 전체 평균보다 낮게 나타나고, 실제 인기도 상승이나 특정 사건으로 정상 리뷰가 몰리는 경우도 존재한다. 그래서 최종 설계에서는 같은 상품-같은 기간이라는 버스트 관계를 엮지로 직접 사용하지 않았다. 대신 상품-주를 샘플링 단위로 사용하고, 그 안에서 리뷰 증가, 신규 사용자 비율, 짧은 리뷰 비율, 평점 이탈, 평점 방향 집중, 동일 텍스트 반복 등 여러 단서가 함께 나타나는지를 확인하였다.

이상의 EDA 결과를 종합하면, 어뷰징 리뷰는 짧은 리뷰, 극단 평점, 신규 사용자, 상품 평판 취약성, 특정 상품-주 구간의 리뷰 집중과 관련이 있다. 그러나 이들 중 어느 하나도 단독으로는 충분하지 않다. 따라서 본 프로젝트의 전처리와 모델링은 단일 규칙 기반 탐지가 아니라, 리뷰 자체 속성, 사용자 과거 맥락, 상품 과거 맥락, 시간적 집중, 리뷰 간 관계를 함께 반영하는 방향으로 설계되었다.

2-2. 전처리 내용

전처리의 첫 단계는 원본 리뷰를 리뷰 노드 중심의 분석 테이블로 정리하는 것이다. 날짜는 시간 순서 계산이 가능하도록 datetime 형식으로 변환하였고, 텍스트 결측은 빈 문자열로 처리하였다. label 은 fake 리뷰를 1, 정상 리뷰를 0 으로 변환하였다. 필수 필드가 결측인 행은 제거하고, 사용자, 상품, 평점, 라벨, 날짜, 텍스트가 모두 동일한 완전 중복 행은 제거하였다. 이 과정은 리뷰 하나가 그래프의 노드 하나로 안정적으로 대응되도록 만들기 위한 단계이다.

두 번째 단계는 리뷰 자체에서 직접 관측 가능한 피처를 만드는 것이다. 평점은 단순 원값뿐 아니라 3 점을 기준으로 한 정규화 값, 부정·중립·긍정 방향, 1 점 또는 5 점에 해당하는 극단 평점 여부로 변환하였다. 이는 평점이 단순한 숫자가 아니라 작성자의 평가 방향을 나타내는 행동 신호이기 때문이다. 텍스트에서는 글자 수, 단어 수, 로그 단어 수, 짧은 리뷰 여부, 고유 토큰 비율, 평균 토큰 길이, 숫자 포함 여부, 대문자 비율, 느낌표와 물음표 개수 등을 추출하였다.

세 번째 단계는 사용자 과거 맥락 피처를 생성하는 것이다. 사용자 ID 를 모델에 직접 넣으면 특정 사용자를 암기하는 방향으로 학습될 수 있으므로 ID 원값은 입력 피처로 사용하지 않았다. 대신 현재 리뷰 작성 시점 이전에 관측 가능한 사용자 이력만 요약하였다. 예를 들어 사용자 과거 리뷰 수, 신규 사용자 여부, 과거 평균 평점, 과거 평점 표준편차, 과거 극단 평점 비율, 마지막 리뷰 이후 경과일, 최근 7 일 또는 30 일 내 이전 리뷰 존재 여부 등을 계산하였다. 이때 현재 리뷰 이후의 사용자 행동은 사용하지 않았다.

네 번째 단계는 상품 과거 맥락 피처를 생성하는 것이다. 상품별로 현재 리뷰 이전에 작성된 리뷰만 사용하여 과거 리뷰 수, 과거 평균 평점, 과거 평점 표준편차, 과거 극단 평점 비율, 최근 7 일과 30 일 리뷰 수, 현재 평점이 과거 상품 평균에서 얼마나 벗어났는지를 계산하였다. 특히 평점 이탈은 절대값만으로 보지 않고, 상품별 과거 평점 표준편차를 고려해 표준화하였다. 이는 원래 평점 변동이 큰 상품과 안정적인 상품을 같은 기준으로 판단하지 않기 위한 조치이다.

다섯 번째 단계는 텍스트 임베딩이다. 본 프로젝트는 비용과 재현성을 고려하여 TF-IDF 와 Truncated SVD 를 사용하였다. 리뷰 원문을 TF-IDF 로 벡터화한 뒤 SVD 를 통해 128 차원 임베딩으로 축소하였다. 이 방식은 대규모 언어모델 임베딩보다 단순하지만, 리뷰 문장에 포함된 단어 패턴을 비교적 낮은 비용으로 모델에 제공할 수 있다. 중요한 점은 TF-IDF 와 SVD 를 train 텍스트에만 fit 하고, validation 과 test 텍스트에는 transform 만 적용했다는 것이다.

여섯 번째 단계는 샘플링과 데이터 분할이다. 전체 리뷰를 그대로 사용하지 않고 먼저 상품 × 주 단위로 GNN 학습에 적합한 서브그래프를 구성하였다. 기본 gate 는 상품-주 리뷰 수 10 개 이상, 고유 사용자 수 8 명 이상이다. 이 gate 를 통과한 후보 안에서 상대 변화량 flag 중 2 개 이상을 만족하는 상품-주를 선택하였다. 최종 샘플은 26,701 개의 리뷰 노드로 구성되며, 선택된 상품-주 구간은 1,957 개이다. 이후 샘플링이 완료된 서브그래프 안에서 시간 순서 기준으로 train 64%, validation 16%, test 20%로 분할하였다.

현재 split 산출물은 train 17,088 개, validation 4,272 개, test 5,341 개의 노드를 포함한다. train 과 validation 을 합치면 전체의 80%이고 test 는 20%이므로, 먼저 샘플링한 뒤 서브그래프 내부에서 학습용 80%, 시험용 20%로 나누라는 가이드라인 조건을 만족한다. split 방식은 temporal 이며 random_state 는 42 로 기록하였다. temporal split 에서는 무작위 섞기가 핵심은 아니지만, 재현성 명시를 위해 해당 값을 산출물에 남겼다.

일곱 번째 단계는 그래프 데이터셋 생성이다. 샘플링된 숫자형 피처와 텍스트 SVD 피처를 결합하여 최종 노드 피처 행렬을 만들고, train mask 기준으로 스케일링 파라미터를 fit 하였다. 최종 topk15 window60 SAGE 기준 그래프의 전체 피처 차원은 174 차원이며, 이 중 숫자형 피처가 46 차원, 텍스트 임베딩이 128 차원이다. 스케일링 기준 역시 train mask 에만 맞추고 validation/test 에는 동일 기준을 적용하여 미래 정보가 평가 구간에서 학습 과정으로 흘러들어가지 않도록 하였다.

2-3. 파생 변수(Feature) 및 그래프 엣지(Edge) 설계 근거

파생 변수 설계의 핵심은 어뷰징 리뷰를 단일 규칙으로 판정하지 않는 것이다. EDA 결과를 보면 fake 리뷰는 짧은 리뷰, 신규 사용자, 극단 평점, 상품의 평판 취약성, 특정 상품-주 구간의 리뷰 집중과 관련이 있었다. 그러나 이들 중 어느 하나도 단독으로는 충분하지 않다. 정상 사용자도 짧은 리뷰를 쓸 수 있고, 실제 경험이 극단적이면 1 점이나 5 점을 줄 수 있다. 따라서 파생 변수는 개별 신호를 절대적 판정 기준으로 쓰기보다, 여러 행동 단서가 함께 나타나는지를 모델이 학습할 수 있도록 구성하였다.

리뷰 자체 피처는 현재 리뷰의 표면적 특성을 나타낸다. 평점 방향, 극단 평점 여부, 단어 수, 짧은 리뷰 여부, 문장부호 사용, 토큰 다양성 등이 여기에 해당한다. 이 피처들은 리뷰 작성자가 얼마나 구체적으로 경험을 설명했는지, 평점이 어느 방향으로 치우쳤는지, 리뷰가 짧고 단정적인 신호만 남기고 있는지를 나타낸다. 행동 데이터 분석 관점에서 리뷰 텍스트는 사용자의 경험 설명이자 동시에 평판에 영향을 주는 행동 결과이므로, 텍스트의 내용 전체를 완벽히 이해하지 못하더라도 길이와 표현 양식은 중요한 보조 신호가 된다.

사용자 맥락 피처는 해당 리뷰를 작성한 사용자의 이전 행동을 요약한다. 신규 사용자 여부, 과거 리뷰 수, 과거 평균 평점, 과거 극단 평점 비율, 마지막 리뷰 이후 경과일은 작성자가 플랫폼에서 어떤 활동 이력을 가졌는지 보여준다. 다만 같은 사용자가 여러 리뷰를 작성했다는 사실 자체를 위험 신호로 보지는 않았다. 활동적인 정상 사용자도 많은 리뷰를 남길 수 있기 때문이다. 따라서 사용자 피처는 사용자를 직접 낙인찍는 정보가 아니라, 현재 리뷰가 작성자의 기존 행동 흐름 속에서 얼마나 자연스러운지를 판단하기 위한 맥락 정보로 사용하였다.

상품 맥락 피처는 현재 리뷰가 상품의 기존 평판 흐름에서 어떤 의미를 가지는지 표현한다. 상품 과거 리뷰 수, 과거 평균 평점, 과거 평점 표준편차, 최근 7 일·30 일 리뷰 수, 현재 평점의 과거 평균 대비 이탈, 평점 이탈의 영향도 등을 계산하였다. 특히 단순 평점 차이보다 중요한 것은 상품별 변동성을 고려한 표준화된 평점 이탈이다. 어떤 상품은 원래 평점 분포가 넓고, 어떤 상품은 안정적인 고평점을 유지한다. 따라서 같은 1 점 차이라도 상품마다 의미가 다를 수 있다.

텍스트 피처는 단순 길이보다 설명 충분성을 중심으로 다듬었다. EDA 상 짧은 리뷰와 극단 평점의 fake rate 가 높았지만, 모든 짧은 극단 리뷰가 fake 는 아니다. 따라서 전체 word length 만 보는 대신, 같은 평점대와 상품 이력 구간

안에서 상대적으로 짧은지를 보는 분위수 피처를 추가하였다. 현재 기준 모델에는 word_len_minus_train_rating_history_median, word_len_ratio_to_train_rating_history_median, is_short_by_train_rating_history_q25, extreme_rating_and_short_by_train_rating_history_q25 등이 포함된다. 이 피처들은 train 기준 분위수와 중앙값을 사용하여 계산한다.

피처 그룹	주요 피처 예시	설계 의도
리뷰 자체 피처	rating_norm, rating_direction, extreme_rating, log_word_len, short_review_flag, punctuation features	현재 리뷰의 평점 방향, 극단성, 설명 길이, 표현 양식을 반영한다.
텍스트 임베딩	TF-IDF + Truncated SVD 128 차원	원문 단어 사용 패턴을 낮은 비용으로 반영하며, train 텍스트에만 fit 한다.
사용자 과거 맥락	prior_user_review_count, prior_user_avg_rating, prior_user_extreme_ratio, days_since_user_last_review	사용자 ID를 암기하지 않고 작성 시점 이전의 활동 흐름만 요약한다.
상품 과거 맥락	prior_product_review_count, prior_product_avg_rating, prior_product_rating_std, product_reviews_last_7d/30d	현재 리뷰가 상품의 기존 평판과 활동량에서 얼마나 벗어났는지 확인한다.
평점 shock 피처	standardized_rating_deviation_from_prior_product_mean, abs_standardized_rating_deviation_from_prior_product_mean	절대 별점 차이가 아니라 상품별 과거 변동성 대비 평점 이탈을 표현한다.
상대적 설명 부족 피처	word_len_ratio_to_train_rating_history_median, is_short_by_train_rating_history_q25	단순히 짧은 리뷰가 아니라 같은 평점대와 상품 이력 구간에서 상대적으로 짧은지를 나타낸다.
샘플링 행동 변화 flag	review_growth, new_user_ratio, short_review_ratio, rating_deviation, rating_direction_concentration, local_template_repeat	상품-주 단위에서 평소 흐름과 다른 변화가 동시에 나타나는 구간을 선택한다.

샘플링 단계의 파생 기준도 같은 논리를 따른다. 최종 샘플링은 상품 × 주 단위로 리뷰 수와 고유 사용자 수의 기본 gate 를 통과한 뒤, 여러 상대 변화량 flag 중 2 개 이상을 만족하는 구간을 선택하였다. 여기서 중요한 점은 절대값이 아니라 과거 흐름 대비 변화량을 중시했다는 것이다. 원래 리뷰가 많은 상품과 조용한 상품은 같은 리뷰 증가라도 의미가 다르기 때문이다. 따라서 “리뷰가 많다”가 아니라 “평소보다 얼마나 달라졌는가”를 기준으로 샘플링하였다.

그래프 엣지는 두 가지로 구성하였다. 첫 번째는 기본 relation 인 R-U-R 엣지이다. 이는 같은 사용자가 작성한 리뷰들을 날짜 기준으로 가까운 리뷰 중심으로 연결한다. 현재 산출물의 R-U-R 은 과거에서 현재로만 향하는 temporal edge 가 아니라, 동일 사용자 리뷰 간의 인접 활동 맥락을 연결하는 recent 방식이다. 이 엣지는 “같은 사용자의 리뷰는 모두 위험하다”는 의미가 아니다. 같은 사용자의 리뷰 흐름을 통해 해당 사용자의 활동 맥락을 GNN 이 참고할 수 있도록 하는 장치이다.

두 번째는 커스텀 relation 인 weak product shock 엣지이다. 이 엣지는 같은 상품의 과거 평점 흐름에 비해 표준화된 평점 이탈이 큰 리뷰 후보들을 연결한다. 구체적으로 중립 평점은 제외하고, 상품 과거 평균 대비 평점 shock 이 일정 수준 이상인 리뷰들을 대상으로 60 일 시간 창 안에서 최대 15 개 수준의 관련 리뷰를 연결하였다. 현재 기준은 shock_score_mode=standardized, shock_min_abs_rating_dev=0.75, shock_date_window_days=60, shock_topk=15 이다.

엣지 유형	연결 기준	현재 산출물	역할
R-U-R	동일 사용자가 작성한 리뷰를 날짜 기준 가까운 리뷰 중심으로 연결	11,038 directed edges	동일 사용자의 과거-인접 활동 맥락을 전달한다.
Weak Product Shock	상품 과거 평균 대비 표준화 평점 이탈이 큰 리뷰를 60 일 창, top-k 15 기준으로 연결	4,266 directed edges	상품 평판 흐름에서 이례적인 평점 이동을 전달한다.

의도적으로 모든 가능한 관계를 사용하지는 않았다. 같은 상품, 같은 기간, 같은 평점 방향의 리뷰를 모두 연결하는 방식은 조직적 행동을 잡는 데 도움이 될 수 있지만, 정상적인 인기 상승이나 실제 사건으로 인한 리뷰 집중까지 함께 묶을 위험이 있다. 실제 실험 과정에서도 정상 버스트와 어뷰징 버스트를 단순 relation 으로 구분하는 방식은 충분히

안정적이지 않았다. 따라서 본 기준 모델은 엣지를 무조건 많이 넣기보다, 동일 사용자 맥락과 상품 평점 shock 이라는 비교적 해석 가능한 두 관계를 중심으로 구성하였다.

최종적으로 사용되는 graph_rur_custom2.pt 는 relation 0 인 R-U-R 11,038 개 directed edge 와 relation 2 인 weak product rating shock 4,266 개 directed edge 를 포함한다. 전체 directed edge 수는 15,304 개이다. relation 1 burst edge 는 제외하였다. 이 구성은 기본 relation 1 개 이상과 커스텀 relation 1 개 이상을 요구하는 가이드라인을 만족하면서도, 정상 리뷰를 과도하게 어뷰징으로 묶을 수 있는 관계를 줄이기 위한 절충이다.

종합하면, 본 프로젝트의 전처리와 모델링 설계는 리뷰 어뷰징을 단순 텍스트 분류 문제가 아니라 행동 네트워크 탐지 문제로 본다. 원본 리뷰를 리뷰 노드로 정리하고, 사용자와 상품의 과거 행동 맥락을 피쳐로 만들며, 상품-주 단위의 변화량을 기준으로 연결성이 살아 있는 서브그래프를 샘플링하였다. 이후 동일 사용자 리뷰 관계와 상품 평점 shock 관계를 그래프 엣지로 정의하여, GNN 이 개별 리뷰의 표면적 특징뿐 아니라 주변 리뷰와의 관계적 맥락까지 학습하도록 하였다. 이 과정에서 라벨, 원본 tag, 전체 기간 fake rate, 미래 리뷰 수처럼 예측 시점에 알 수 없거나 정답을 직접 반영하는 정보는 입력에서 제외하였다.