

3. 모델 선택 이유와 적용 과정

3-1. 선택한 모델

본 프로젝트에서 보고서의 기준 모델로 설명하는 구조는 topk15 window60 SAGE 이다. 입력 그래프는 data/graph_relflag_edge_t15_w60_thr075/graph_rur_custom2.pt 이며, 이 그래프는 26,701 개의 리뷰 노드, 174 차원 노드 피처, 15,304 개의 directed edge 로 구성된다. 노드는 원본 리뷰 한 행에 대응되며, 엣지는 동일 사용자 기반 R-U-R relation 과 상품 평점 shock 기반 커스텀 relation 으로 구성된다.

이 모델은 plain GraphSAGE 이다. 즉 relation_sage 나 R-GCN 처럼 edge_type 별로 서로 다른 파라미터를 두는 모델은 아니다. 그래프 파일 안에는 R-U-R edge 와 weak product shock edge 가 함께 들어 있지만, 학습 단계의 plain SAGE 는 edge_type 을 직접 구분하지 않고 edge_index 에 포함된 이웃 정보를 하나의 그래프로 집계한다. 따라서 보고서에서는 두 relation 의 의미를 엣지 설계 논리와 해석에서 구분하되, 모델 구조가 relation 별 가중치를 학습한다고 설명해서는 안 된다.

최종 기준 모델의 이름에 포함된 topk15 window60 은 weak product shock edge 를 만드는 방식에서 온 표현이다. 상품의 과거 평균 평점 대비 현재 리뷰의 평점 이탈을 상품별 과거 평점 표준편차로 표준화하고, 그 이탈이 일정 수준 이상인 리뷰를 후보로 삼은 뒤, 60 일 시간 창 안에서 최대 15 개 수준의 관련 리뷰를 연결하였다. 이 방식은 단순히 별점 차이가 큰 리뷰를 모두 연결하는 것이 아니라, 상품별 평소 변동성을 고려해 이례적인 평점 이동을 포착하려는 설계이다.

구분	현재 기준
모델 구조	2-layer plain GraphSAGE
입력 그래프	graph_rur_custom2.pt
노드	리뷰 단위 노드 26,701 개
피처	숫자형 46 차원 + TF-IDF/SVD 텍스트 128 차원 = 총 174 차원
엣지	R-U-R 11,038 개 + weak product shock 4,266 개
학습 설정	hidden_dim 128, dropout 0.5, learning rate 0.001, weight decay 0.0001

3-2. 모델 선택 이유

모델 선택의 첫 번째 기준은 학술제 가이드라인과의 정합성이다. 가이드라인은 리뷰 단위 노드, 기본 relation 1 개 이상, 커스텀 relation 1 개 이상, GNN 계열 모델의 핵심 사용을 요구한다.

topk15 window60 SAGE 는 리뷰를 노드로 두고, 기본 relation 으로 동일 사용자 기반 R-U-R 을 사용하며, 커스텀 relation 으로 상품 평점 shock edge 를 사용하므로 이 조건을 만족한다.

두 번째 기준은 모델 구조의 비용 대비 효율성과 유지보수성이다. 현재 그래프는 26,701 개 노드에 15,304 개 directed edge 를 가지며, 전체 노드 중 연결되지 않은 노드도 적지 않다. 이런 sparse graph 에서는 지나치게 복잡한 attention 구조나 relation 별 고차원 파라미터를 둔 모델이 항상 유리하지 않다. GraphSAGE 는 구조가 비교적 단순하고, 노드 자신의 피처와 이웃 피처를 함께 사용해 리뷰 자체 정보와 관계 정보를 동시에 반영할 수 있다.

세 번째 기준은 해석 가능성이다. 본 프로젝트의 핵심은 단순히 텍스트 분류 모델을 만드는 것이 아니라, 리뷰가 어떤 사용자 맥락과 상품 평판 맥락 속에서 발생했는지를 설명하는 것이다. GraphSAGE 는 plain 구조이므로 relation 별 효과를 직접 분해해서 보여주지는 못하지만, R-U-R 과 shock edge 를 통해 연결된 이웃 리뷰의 정보를 현재 리뷰 표현에 반영한다. 따라서 최종 예측을 해석할 때 리뷰 자체 피처, 동일 사용자 리뷰 흐름, 상품 평점 shock 관계를 함께 확인하는 방식으로 설명할 수 있다.

다만 최근 추가 비교에서 SAGE 를 GCN 으로 교체했을 때 일부 성능이 개선된 결과가 있었으므로, GCN 을 완전히 배제할 필요는 없다. GCN 은 degree normalization 과 self-loop 기반의 보수적인 정보 확산을 수행하므로, 현재처럼 sparse 하고 node feature 가 강한 그래프에서는 오히려 더 안정적으로 작동할 수 있다. 그러나 현재 프로젝트 파일과 실행 안내에서 최종 실행 기준으로 보존된 모델은 topk15 window60 SAGE 이며, GCN 결과는 후속 후보 또는 추가 비교 실험으로 다루는 것이 사실관계에 맞다.

모델 후보	해석
topk15 window60 SAGE	현재 프로젝트에서 보존된 최종 실행 기준 모델이다. R-U-R 과 weak product shock edge 를 하나의 message passing 그래프로 사용한다.
GCN	동일 구조에서 SAGE 를 GCN 으로 바꾸면 일부 성능이 개선될 수 있는 후보이다. 다만 현재 기본 실행 산출물은 SAGE 기준이다.
relation_sage / R-GCN	edge_type 별 파라미터를 둘 수 있어 relation 해석에는 유리하지만, 현재 최종 실행 기준 모델은 아니다.
MLP	edge 를 사용하지 않는 feature-only 기준선으로 볼 수 있으나, GNN 활용이라는

	대회 목적에는 단독 모델로 적합하지 않다.
--	-------------------------

3-3. 모델 적용 과정

모델 적용은 샘플링, split, 텍스트 임베딩, 엣지 생성, 그래프 생성이 끝난 뒤 진행하였다. 학습 스크립트는 graph_rur_custom2.pt 에 저장된 x, y, edge_index, train_mask, valid_mask, test_mask 를 불러온다. 여기서 x 는 숫자형 피처와 텍스트 SVD 피처를 결합한 노드 피처이며, y 는 fake=1, normal=0 으로 변환된 라벨이다. train, validation, test mask 는 샘플링이 완료된 26,701 개 노드 안에서 시간 순서 기준으로 나뉜다.

학습 단계에서는 클래스 불균형을 고려하였다. train split 에는 정상 리뷰가 fake 리뷰보다 훨씬 많기 때문에, 단순 cross entropy loss 만 사용하면 모델이 정상 리뷰 예측에 치우칠 수 있다. 이를 완화하기 위해 train split 의 클래스 빈도에 반비례하는 inverse-frequency class weight 를 적용하였다. 이 가중치는 fake 클래스의 오분류 손실을 상대적으로 크게 반영하여, 모델이 소수 클래스 탐지도 함께 학습하도록 돕는다.

학습 설정은 hidden dimension 128, layer 수 2, dropout 0.5, learning rate 0.001, weight decay 0.0001, 최대 epoch 200, early stopping patience 30 이다. early stopping 기준은 validation PR-AUC 이다. 즉 모델은 train 성능이 아니라 validation 에서 fake 리뷰를 확률 순위 상단에 잘 배치하는지를 기준으로 best epoch 를 선택한다. 최종 best epoch 는 71 이다.

threshold 는 test 결과를 보고 고르지 않았다. validation split 에서 prevalence-constrained Macro F1 기준으로 선택했으며, 최종 threshold 는 0.75 이다. 따라서 test set 은 학습 과정과 threshold 선택 과정에서 직접 사용되지 않고, 최종 일반화 성능을 확인하는 용도로만 사용되었다.

단계	내용	의미
1 단계	그래프 로드	x, y, edge_index, train/valid/test mask 를 불러온다.
2 단계	학습	class weight 를 적용한 cross entropy loss 와 Adam optimizer 를 사용한다.
3 단계	best epoch 선택	validation PR-AUC 기준으로 early stopping 을 수행한다.
4 단계	threshold 선택	validation 기준 prevalence-constrained Macro F1 로 threshold 를 정한다.

5 단계	test 평가	고정된 모델과 threshold 로 test PR-AUC, Macro F1 등을 계산한다.
------	---------	--

4. 모델 성능 평가 및 결과 해석

4-1. 평가 지표 선정 및 근거

본 프로젝트는 fake 리뷰가 정상 리뷰보다 적은 불균형 이진 분류 문제이다. 전체 원본 데이터의 fake rate 는 약 13.22%이고, 최종 샘플 전체의 fake rate 는 약 16.04%이다. test split 의 fake rate 는 약 21.42%로 train split 보다 높다. 따라서 단순 Accuracy 만으로는 모델의 실질적인 탐지 능력을 평가하기 어렵다.

PR-AUC 는 fake 리뷰처럼 소수 클래스인 대상을 확률 순위 상단에 얼마나 잘 배치하는지 보여준다. 실제 운영에서 모든 리뷰를 한 번에 제재하기보다 의심도가 높은 리뷰부터 검토한다면 PR-AUC 는 매우 중요한 지표가 된다. 또한 PR-AUC 는 학술제 가이드라인에서 보고해야 하는 핵심 지표이다.

Macro F1 은 정상 리뷰와 fake 리뷰 각각의 F1 을 동일한 비중으로 평균한 지표이다. 이는 다수 클래스인 정상 리뷰에만 치우친 모델인지 확인하는 데 유용하다. threshold 를 실제로 적용해 의심 리뷰를 분류하는 상황에서는 PR-AUC 와 함께 Macro F1 을 보는 것이 타당하다. ROC-AUC 는 전체 threshold 구간에서의 분류 변별력을 보는 보조 지표이며, Precision 과 Recall 은 오탐과 미탐의 균형을 직접 확인하기 위해 사용하였다.

4-2. 모델 성능 결과

최종 기준 모델은 topk15 window60 SAGE 이다. 모델 평가는 validation 기준으로 선택된 best epoch 와 threshold 를 고정한 뒤 test split 에서 수행하였다. 아래 표는 현재 보존된 metrics.json 의 test 성능을 기준으로 정리한 것이다.

항목	값	해석
모델	topk15 window60 SAGE	현재 실행 기준으로 보존된 최종 SAGE 모델
PR-AUC	0.4901	불균형 데이터에서 fake 리뷰 순위를 얼마나 잘 올리는지 보여주는 핵심 지표
ROC-AUC	0.7851	정상과 fake 를 전반적으로 구분하는 순위 성능
Macro F1	0.6793	정상 클래스와 fake 클래스를

		같은 비중으로 본 분류 균형
Precision	0.4956	fake 로 예측한 리뷰 중 실제 fake 의 비율
Recall	0.4965	실제 fake 리뷰 중 모델이 탐지한 비율
Accuracy	0.7839	전체 리뷰 중 올바르게 분류한 비율
Threshold	0.75	validation split 에서 선택한 기준값이며 test 성능 산출에는 새로 조정하지 않음

검증 성능은 validation PR-AUC 0.3940, validation Macro F1 0.6458 이다. train 성능은 PR-AUC 0.5889, ROC-AUC 0.8959, Macro F1 0.7331 이다. train 성능이 test 성능보다 높으므로 과적합 가능성을 완전히 배제할 수는 없지만, 최종 test 기준에서 PR-AUC, ROC-AUC, Macro F1, Precision, Recall 의 균형을 확인할 수 있다.

평가 지표	성능값	해석
PR-AUC	0.4901	fake 리뷰를 위험도 순위 상단에 배치하는 능력
ROC-AUC	0.7851	threshold 전반에서의 분류 변별력
Macro F1	0.6793	정상/fake 양쪽을 고려한 균형 분류 성능
Precision	0.4956	fake 로 예측한 리뷰 중 실제 fake 인 비율
Recall	0.4965	실제 fake 리뷰 중 모델이 탐지한 비율
Accuracy	0.7839	전체 리뷰 중 올바르게 분류한 비율

4-3. 결과 해석

Test PR-AUC 0.4901 은 완전히 높은 수준이라고 보기는 어렵지만, 클래스 불균형 상황에서 fake 리뷰를 확률 순위 상단에 일정 수준 배치할 수 있음을 의미한다. 이 지표는 운영자가 검토 대상을 우선순위화할 때 직접적으로 의미가 있다. 다만 PR-AUC 만으로 모델을 자동 제재 시스템처럼 사용하기에는 조심해야 한다.

Test ROC-AUC 0.7851 은 threshold 를 다양하게 바꾸어도 모델이 정상 리뷰와 fake 리뷰를 구분하는 전반적인 변별력을 가진다는 뜻이다. ROC-AUC 는 클래스 비율의 영향을 PR-AUC 보다 덜 받기 때문에, 모델이 전체적으로 두 클래스를 분리할 수 있는지를 확인하는 보조 지표로 해석하는 것이 적절하다.

Test Macro F1 0.6793 은 threshold 를 적용한 실제 분류 상황에서 정상 리뷰와 fake 리뷰 양쪽을 어느 정도 균형 있게 고려했음을 보여준다. Precision 0.4956 과 Recall 0.4965 는 거의 비슷한 수준이다. 이는 모델이 fake 리뷰를 과도하게 많이 예측하는 방향이나, 지나치게 보수적으로 예측하는 방향 중 한쪽으로 크게 치우치지는 않았다는 뜻이다.

Accuracy 0.7839 는 겉으로는 높은 편이지만, 본 문제에서는 정상 리뷰가 더 많은 불균형 데이터이므로 Accuracy 만으로 성능을 판단해서는 안 된다. 최종 해석에서는 PR-AUC 와 Macro F1 을 중심으로 보고, Precision 과 Recall 을 함께 확인하는 것이 타당하다. 따라서 이 모델은 자동 판정 모델이라기보다, 검수 우선순위를 제공하는 GNN 기반 위험도 산정 모델로 해석하는 것이 더 적절하다.

5. 모델 기반 인사이트 및 활용 방안

5.1 모델 기반 주요 인사이트

첫째, 리뷰 어뷰징은 개별 리뷰의 문장만으로 판단하기 어렵고, 사용자·상품·시간 맥락과 함께 보아야 한다. 최종 모델은 리뷰 자체 피쳐, 사용자 과거 맥락, 상품 과거 맥락, 텍스트 임베딩, R-U-R edge, weak product shock edge 를 함께 사용한다. 따라서 단일 리뷰가 짧거나 극단 평점을 가졌다는 이유만으로 판단하지 않고, 해당 리뷰가 어떤 관계 구조 안에서 나타났는지를 함께 반영한다.

둘째, 절대적인 평점 차이보다 상품별 과거 변동성을 고려한 표준화 평점 이탈이 더 해석 가능하다. 같은 1 점 차이라도 평소 평점 변동이 큰 상품과 안정적인 상품에서 의미가 다르기 때문이다. 최종 모델은 $\text{standardized_rating_deviation_from_prior_product_mean}$ 과 $\text{abs_standardized_rating_deviation_from_prior_product_mean}$ 을 사용하여 현재 리뷰가 상품의 과거 평판 흐름에서 얼마나 벗어났는지를 표현한다.

셋째, 같은 사용자 relation 은 위험 전파용 relation 이 아니라 사용자 맥락 전달용 relation 으로 해석해야 한다. 같은 사용자가 여러 리뷰를 작성했다는 사실만으로 위험하다고 볼 수는 없다. 실제 활동적인 정상 사용자도 많은 리뷰를 남긴다. R-U-R edge 는 해당 사용자의 인접 리뷰 흐름을 GNN 이 참고하게 하는 장치이며, 사용자를 직접 낙인찍는 기준이 아니다.

넷째, 현재 plain SAGE 는 relation type 자체를 구분하지 않는다. 따라서 R-U-R 과 weak product shock 의 의미는 엣지를 설계한 사람이 해석할 때 구분되지만, 모델 내부에서는 하나의 edge_index 로 합쳐져 message passing 이 이루어진다. 이 점은 결과를 설명할 때 중요한 사실관계이다. relation 별 효과를 직접 분리해 보고 싶다면 relation_sage 나 R-GCN 같은 구조를 후속 후보로 검토해야 한다.

다섯째, 성능만으로 모델을 평가하기보다 운영 목적을 함께 보아야 한다. PR-AUC 는 의심 리뷰를 순위화하는 능력에 가깝고, Macro F1 은 실제 threshold 를 적용했을 때의 균형 분류 성능에 가깝다. 현재 모델은 PR-AUC 개선 여지는 남아 있지만, threshold 적용 후 Precision 과 Recall 이 균형을 이루고 있다는 점에서 검수 보조 모델로 활용할 수 있다.

5.2 모델 활용 방안

첫 번째 활용 방안은 리뷰 검수 우선순위 산정이다. 최종 모델은 각 리뷰에 대해 fake 확률을 산출한다. 따라서 모든 리뷰를 동일하게 검수하기보다, fake 확률이 높은 리뷰를 우선 검토하면 제한된 운영 인력으로 더 효율적인 검수가 가능하다. 다만 모델 예측은 최종 판정이 아니라 검수 우선순위 신호로 사용해야 한다.

두 번째 활용 방안은 validation 기준 threshold 0.75 를 이용한 1 차 후보 선별이다. 현재 모델에서 prob_fake 가 0.75 이상인 리뷰는 1 차 의심 리뷰로 분류할 수 있다. 그러나 이 기준은 자동 삭제나 자동 제재 기준이라기보다 운영자가 먼저 확인해야 할 후보를 정하는 기준으로 보는 것이 바람직하다.

세 번째 활용 방안은 상품 단위 shock 모니터링이다. weak product shock edge 는 상품의 과거 평점 흐름 대비 이례적인 평점 이동을 가진 리뷰들을 연결한다. 특정 상품에서 짧은 기간 안에 유사한 shock 리뷰가 반복적으로 발생하면, 해당 상품을 평판 조작 또는 공격성 리뷰 집중 후보로 모니터링할 수 있다.

네 번째 활용 방안은 사용자 단위 맥락 확인이다. R-U-R edge 는 같은 사용자의 리뷰 이력을 연결하므로, 높은 fake 확률을 받은 리뷰가 있을 때 해당 사용자의 인접 리뷰 흐름을 함께 확인할 수 있다. 이 과정은 사용자를 자동으로 제재하기 위한 것이 아니라, 해당 리뷰가 작성자의 평소 행동과 얼마나 다른지를 검토하는 보조 절차로 이해해야 한다.

다섯 번째 활용 방안은 검수 사유 설명 보조이다. 운영자는 특정 리뷰가 의심 리뷰로 분류되었을 때, 상품 과거 평균 대비 평점 이탈, 과거 상품 리뷰 수, 텍스트 설명 길이, 동일 사용자 리뷰 흐름, shock edge 연결 여부 등을 함께 확인할 수 있다. 이는 모델 결과를 단순 확률값으로만 제시하는 것보다 사람이 납득하기 쉬운 검수 근거를 제공한다.

6. 모델링의 한계와 보완 계획

6.1 그래프 구조의 희소성

현재 그래프는 26,701 개 노드와 15,304 개 directed edge 로 구성된다. 전체 평균 degree 는 높지 않으며, 전체 기준 isolated node 도 19,916 개로 나타난다. GraphSAGE 는 자기 자신의 노드 피쳐도 사용하므로 isolated node 에 대해서도 예측은 가능하지만, 이 경우 예측은 graph message passing 보다는 node feature 기반 분류에 가까워진다. 따라서 현재 모델의 GNN 효과는 실제로 연결된 노드에서 더 강하게 작동한다고 해석하는 것이 정확하다.

보완 방향은 edge coverage 를 높이는 것이다. 다만 단순히 edge 를 많이 추가하는 것이 항상 좋은 것은 아니다. 같은 상품, 같은 기간, 같은 평점 방향의 리뷰를 모두 연결하면 정상적인 인기 상승이나 실제 사건에 따른 리뷰 집중도 함께 묶일 수 있다. 따라서 후속 실험에서는 동일 상품 내 시간적으로 인접한 리뷰, 텍스트 유사도가 높은 리뷰, 신규 사용자 집중 상품-주 리뷰 등 후보 relation 을 성능과 오탐 위험을 함께 보며 제한적으로 검토하는 것이 적절하다.

6.2 시간 정보 반영의 제약

현재 R-U-R edge 는 `ur_temporal=false` 이며, 동일 사용자의 리뷰를 날짜 기준 가까운 리뷰 중심으로 연결한다. weak product shock edge 역시 60 일 window 안의 유사 shock 리뷰를 연결하지만, 모든 edge 가 엄격한 과거→현재 인과 관계를 의미하는 것은 아니다. 따라서 이 모델은 오프라인 분석과 검수 우선순위 산정에는 적합하지만, 실시간 탐지 환경에서 미래 정보를 절대 사용하지 않는 구조라고 표현해서는 안 된다.

후속 보완에서는 edge 방향을 과거 리뷰에서 현재 리뷰로 제한하는 temporal edge 설계를 적용할 수 있다. 예를 들어 동일 사용자의 과거 리뷰만 현재 리뷰로 연결하거나, 상품의 과거 리뷰 흐름에서 현재 shock 리뷰로만 연결하는 방식이 가능하다. 이 경우 실제 운영 시점에 더 가까운 평가가 가능하지만, edge 수가 줄어들어 그래프가 더 희소해질 수 있으므로 성능과 해석 가능성을 함께 비교해야 한다.

6.3 relation type 미분리의 한계

현재 기준 모델은 plain SAGE 이므로 R-U-R edge 와 weak product shock edge 를 별도 relation 파라미터로 분리하지 않는다. 이는 모델을 단순하고 안정적으로 유지하는 장점이 있지만, 어떤 relation 이 예측에 더 크게 기여했는지 모델 내부에서 직접 분해하기 어렵다는 한계가 있다. 보고서나 발표에서는 “두 relation 을 각각 다른 방식으로 학습했다”고 설명하기보다, “두 relation 을 하나의 message passing 그래프에 포함시켰다”고 설명해야 사실관계에 맞다.

후속 연구에서는 `relation_sage` 나 R-GCN 처럼 `edge_type` 을 직접 사용하는 모델을 비교할 수 있다. 다만 relation 별 모델은 파라미터가 늘어나고, 현재 그래프처럼 edge 가 희소한 조건에서는 오히려 불안정해질 수 있다. 따라서 relation-aware 모델을 도입할 때에는 PR-AUC, Macro F1 뿐 아니라 relation 별 edge coverage, isolated node 비율, 오탐 사례를 함께 검토해야 한다.

6.4 성능과 운영 적용의 한계

최종 모델의 test PR-AUC 는 0.4901 이고 Precision 과 Recall 은 약 0.50 수준이다. 이는 검수 우선순위 모델로는 의미가 있지만, 자동 제재 모델로 바로 사용하기에는 충분하지 않다. 특히 정상 사용자의 실제 불만 리뷰나 짧은 만족 리뷰를 잘못 제재하면 서비스 신뢰도에 문제가 생길 수 있다. 따라서 현재 모델은 운영자의 검수를 보조하는 위험도 산정 모델로 활용하고, 최종 제재 여부는 사람이 리뷰 본문과 상품·사용자 맥락을 함께 확인한 뒤 결정하는 것이 적절하다.

또한 현재 성능은 seed 42 와 현재 split 기준의 결과이다. 시간 기준 split 을 사용했기 때문에 실제 운영 상황과 어느 정도 유사하지만, 다른 기간이나 다른 플랫폼에서도 같은 성능이 유지된다고 단정할 수는 없다. 후속 단계에서는 seed 반복 실험, 기간별 성능 분석, 상품군별 성능 분석, GCN 후보와의 재비교를 통해 모델 안정성을 더 확인할 필요가 있다.